

Metody Najlepszej Wiarogodnosci

1 Estymacja metoda najlepšej wiarogodnosťi.
 Zaletmy, že X_1, \dots, X_n sú nerevnými miennymi losovými
 o tých samých rozdeleníach \approx gestačia $f(x|\theta)$, $\theta \in \Theta \subseteq \mathbb{R}^p$, $p \geq 1$.

Def 1

Funkcia $L: \Theta \rightarrow \mathbb{R}$ postaví

$$L(\theta) = L(\theta, x) = \prod_{i=1}^n f(x_i | \theta), \quad \theta \in \Theta,$$

gde $x = (x_1, \dots, x_n)$, nazívame funkciu wiarogodnosći.

Funkcia $\ell: \Theta \rightarrow \mathbb{R}$ postaví

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i | \theta), \quad \theta \in \Theta$$

nazívame logaritmom wiarogodnosći (logwiarogodnosť).

Priklad 1

Niech X_1, \dots, X_n bude próbou losovania z rozdelenia

$$P(x) = \begin{cases} \theta^x (1-\theta)^{1-x}, & x=0,1, \\ 0 & \text{in} \neq 0,1 \end{cases}$$

dla $\theta \in [0,1]$. Dla $x_i = 0,1$, $i = 1, \dots, n$,

$$P(X = x) = P((X_1, \dots, X_n) = (x_1, \dots, x_n)) = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i},$$

Takže

$$L(\theta) = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i}, \quad 0 < \theta < 1.$$

Problém: Jako hodnotu θ máme vymaliť aby pravdepodobenstvo $L(\theta)$ pôsobiaci na observované próby x_1, \dots, x_n ? [Dobry estymator θ ?]

Máme $\ell(\theta) = \log L(\theta) = (\sum_{i=1}^n x_i) \log \theta + (n - \sum_{i=1}^n x_i) \log (1-\theta)$

$$\frac{d\ell(\theta)}{d\theta} = \frac{\sum_{i=1}^n x_i}{\theta} - \frac{n - \sum_{i=1}^n x_i}{1-\theta} = 0, \quad \theta \neq 0, 1$$

$$(1-\theta)\sum_{i=1}^n x_i - \theta(n - \sum_{i=1}^n x_i) = \sum_{i=1}^n x_i - \theta n = 0 \Rightarrow \hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

$$-\frac{n\bar{x}}{\bar{x}^2} \neq \frac{n-n\bar{x}}{(1-\bar{x})^2} = -\frac{n}{\bar{x}} \neq \frac{n}{1-\bar{x}} = \frac{-n+n\bar{x}}{\bar{x}(1-\bar{x})} = \frac{-n}{\bar{x}(1-\bar{x})} < 0$$
(32)

Statystyka

$$\hat{\theta} = \bar{X}$$

jest nazywana estymatorem największej wiarygodności parametru θ .

Niech Θ_0 będzie prawdziwą wartością parametru θ .

Zalotenia (warunki regularności)

(R0) : Jeżeli $\theta \neq \theta'$, to $f(x_i, \theta) \neq f(x_i, \theta')$ dla każdego $x_i \in \mathbb{R}$.

(R1) : Gęstość $f(x_i, \theta)$, $i=1, \dots, n$ ma taki sam nośnik dla wszystkich θ . Nośnik f nie zależy od θ .

(R2) : $\Theta_0 \in \text{int } H$.

Tu 1

Przy założeniach (R0)-(R1)

$$\lim_{n \rightarrow \infty} P_{\theta_0} [L(\theta_0, X) > L(\theta, X)] = 1, \text{ dla wszystkich } \theta \neq \theta_0.$$

prawdziwy model
 jest
 asymptotycznie
 niezależny od falsyfikatora

Dowód

1. Mamy $L(\theta_0, X) > L(\theta, X) \Leftrightarrow \prod_{i=1}^n f(\theta_0, x_i) > \prod_{i=1}^n f(\theta, x_i) \Leftrightarrow$

$$\sum \log f(\theta_0, x_i) > \sum \log f(\theta, x_i) \Leftrightarrow \frac{1}{n} \sum_{i=1}^n \log \left(\frac{f(\theta, x_i)}{f(\theta_0, x_i)} \right) < 0.$$

2. Ponieważ $\log \left(\frac{f(\theta, x_i)}{f(\theta_0, x_i)} \right)$, $i=1, \dots, n$ są iid, SPUL implikuje

$$\frac{1}{n} \sum_{i=1}^n \log \left[\frac{f(x_i, \theta)}{f(x_i, \theta_0)} \right] \xrightarrow{P} E_{\theta_0} \left[\log \frac{f(x_1, \theta)}{f(x_1, \theta_0)} \right]$$

nier. Jensen
 skutek depech

$$3. \text{ Porzątko, } E_{\theta_0} \log \int_{\mathbb{R}} \frac{f(x_1, \theta)}{f(x_1, \theta_0)} f(x_1, \theta_0) dx_1 = \log \int_{\mathbb{R}} f(x_1, \theta) dx_1 = \log 1 = 0$$

Uwaga 1

Tera twierdzenia mówi, że, asymptotycznie, funkcja wiarygodności

jest maksymalizowana w punkcie θ_0 (czyli prawdziwej wartością parametru θ).

Def 2

Mówimy, że $\hat{\theta} = \hat{\theta}(x)$ jest estymatorem naiwspolszej wia-ogodności (NW) parametru θ , ~~wtedy, i tylko~~ jeśli

$$\hat{\theta} = \underset{\theta \in \Theta}{\operatorname{argmax}} L(\theta, x)$$

czyli $L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta, x).$

Uwaga 2

Estymator NW może nie istnieć lub może nie być wyznaczony jednoznacznie

Przykład 2

x_1, \dots, x_n iid $X_i \sim f(x|\theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$ $\mathbb{I}_{(0,+\infty)}(x)$.

$$\frac{1}{\theta} e^{-\frac{x}{\theta}}$$

$$L(\theta) = \left(\frac{1}{\theta}\right)^n e^{-\frac{1}{\theta} \sum x_i}$$

$$\ell(\theta) = -n \log \theta - \frac{1}{\theta} \sum x_i$$

$$\frac{\partial \ell(\theta)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum x_i = 0 \Leftrightarrow n\theta = \sum x_i \quad \hat{\theta} = \overline{x}$$

$$\frac{\partial^2 \ell(\theta)}{\partial \theta^2} = \frac{1}{\theta^2} - \frac{2}{\theta^3} \sum x_i = \frac{1}{\theta^3} (\theta - 2 \sum x_i) \Big|_{\hat{\theta} = \bar{x}} = \frac{1}{\bar{x}^3} (\bar{x} - 2n\bar{x})$$

naleśnun.

Przykład 3

x_1, \dots, x_n iid $X_i \sim f(x|\theta) = \frac{1}{2} e^{-|x-\theta|}$, $x, \theta \in \mathbb{R}$.

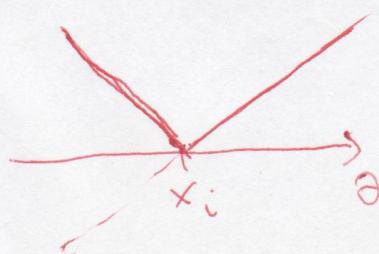
$$L(\theta) = \left(\frac{1}{2}\right)^n e^{-\sum |x_i - \theta|}$$

$$\ell'(\theta) = -n \log 2 - \sum_{i=1}^n |x_i - \theta|$$

$$\ell'(\theta) = \sum_{i=1}^n \operatorname{sgn}(x_i - \theta) = 0 \Rightarrow \hat{\theta} = \operatorname{med}\{x_1, \dots, x_n\}$$

$$x_i - \theta > 0 \quad 1$$

$$x_i - \theta < 0 \quad 1$$



$$\sum_{i=1}^n \operatorname{sgn}(x_i - x_{(2)})$$

$$|\theta - x_i|$$

Przykład 4

x_1, \dots, x_n iid, $x_i \sim U(0, \theta)$, $f(x_i | \theta) = \frac{1}{\theta} I_{(0, \theta)}(x_i)$ (R1)! nie jest spełniony

$$L(\theta) = \left(\frac{1}{\theta}\right)^n \prod_{i=1}^n I_{(0, \theta)}(x_i) = \left(\frac{1}{\theta}\right)^n \underbrace{\prod_{i=1}^n}_{\text{! } 0 \leq x_i \leq \theta} I_{[0, +\infty)}(x_{(1)}) I_{(-\infty, \theta]}(x_{(n)})$$

$$\hat{\theta} = X_{(n)}$$

$$\begin{aligned} & \forall \quad 0 \leq x_i \leq \theta \\ & 0 \leq x_{(1)} \wedge x_{(n)} \leq \theta \end{aligned}$$

Tu 2

Niech x_1, \dots, x_n będzie próbą prostą o gęstości $f(x_i | \theta), \theta \in \mathbb{H}$.

Niech $g: \mathbb{H} \rightarrow \mathbb{R}$ będzie dowolną funkcją, a $\eta = g(\theta)$ estymowanym parametrem. Założymy, że $\hat{\theta}$ jest ENW parametru θ . Wtedy $g(\hat{\theta})$ jest ENW parametru $\eta = g(\theta)$.

Dowód

I) Założymy, że g jest różniczkowalna.

1. wtedy

$$\max_{\eta \in g(\mathbb{H})} L(\eta) = \max_{g(\theta) \in g(\mathbb{H})} L(g(\theta)) = \max_{\eta = g(\theta)} L(\eta) = \max_{\theta \in \mathbb{H}} L(g^{-1}(\theta)) = \max_{\theta \in \mathbb{H}} L(\hat{\theta})$$

z założenia

Tu 3

Założymy, że x_1, \dots, x_n są niezależnymi zmiennymi losowymi o tym samym rozkładzie, który gęstość spełniają warunki (R0)-(R2). Ponadto, założymy, że $f(x_i | \theta)$ jest różniczkowalna względem θ . Wtedy, równanie różniczkowe

$$\frac{\partial}{\partial \theta} L(\theta) = 0 \quad \text{lub różnicznie} \quad \frac{\partial}{\partial \theta} l(\theta) = 0$$

ma rozwiązanie $\hat{\theta}_n$, takie że $\hat{\theta}_n \xrightarrow{P} \theta_0$.

Tu 4

Przy założeniach tu 3, niech $\hat{\theta}_n$ będzie jedynym rozwiązaniem równania $\frac{\partial}{\partial \theta} L(\theta) = 0$. Wtedy $\hat{\theta}_n$ jest zgodnym estymatorem parametru θ_0 .

Niech X býva zmienna losová o gestosei $f(x|\theta)$, $\theta \in \Theta$,
kde Θ je závesen otvoren.

Záloženia (dodatkove warunki regulárnosť)

(R3) Gestosí $f(x|\theta)$ je dvekrátne rôznicikovadna
uzľeden parametru θ .

(R4) $\int_{-\infty}^{\infty} f(x|\theta) dx$ ~~nestoje~~ je dvekrátne rôznicikovadna
uzľeden θ pod znakom čiarky.

Uvaha 1

Warunki (R1)-(R4) označajú, že parametr θ nie pojavi sa
na konciach povedanu, dla ktorého $f(x|\theta) > 0$ oraz, že moteny
zamieniajú čiarkovanie s rôznicikovaním uzľeden θ .

Mamy

$$1 = \int_{-\infty}^{\infty} f(x|\theta) dx \quad / \frac{\partial}{\partial \theta}$$

$$0 = \int_{-\infty}^{\infty} \frac{\partial f(x|\theta)}{\partial \theta} dx$$

rôznicikovanie

$$0 = \int_{-\infty}^{\infty} \frac{\partial f(x|\theta)/\partial \theta}{f(x|\theta)} f(x|\theta) dx = \int_{-\infty}^{\infty} \frac{\partial \log f(x|\theta)}{\partial \theta} f(x|\theta) dx$$

Iatrem $E\left[\frac{\partial \log f(x|\theta)}{\partial \theta}\right] = 0$

Ponadto, rôznicikujec

$$0 = \int_{-\infty}^{\infty} \frac{\partial \log f(x|\theta)}{\partial \theta} f(x|\theta) dx \quad \text{uzľeden } \theta \text{ otrzymujem}$$

$$0 = \int_{-\infty}^{\infty} \frac{\partial^2 \log f(x|\theta)}{\partial \theta^2} f(x|\theta) dx + \int_{-\infty}^{\infty} \frac{\partial \log f(x|\theta)}{\partial \theta} \frac{\partial \log f(x|\theta)}{\partial \theta} f(x|\theta) dx$$

Rôznicikovanie

$$= \int_{-\infty}^{\infty} \frac{\partial^2 \log f(x|\theta)}{\partial \theta^2} f(x|\theta) dx = E\left[\frac{\partial \log f(x|\theta)}{\partial \theta}\right]^2 \underbrace{\frac{\partial f(x|\theta)}{\partial \theta}}$$

Def 1

Informacja Fishera dla parametru θ nazywany limb (wektor)

$$I(\theta) = E \left[\left(\frac{\partial \log f(x, \theta)}{\partial \theta} \right)^2 \right].$$

Wniosek 1 Przy założeniu warunków regularności (R0)-(R4)

$$I(\theta) = - \int_{-\infty}^{\infty} \frac{\theta^2 \log f(x, \theta)}{\partial \theta^2} f(x, \theta) dx = \text{Var} \left[\frac{\partial \log f(x, \theta)}{\partial \theta} \right].$$

Def 2

Funkcja

$$\frac{\partial \log f(x, \theta)}{\partial \theta}$$

najw霎y funkcji wynikowej.

Przykład 1

$$X \sim B(1|\theta), \quad f(x|\theta) = \theta^x (1-\theta)^{1-x}$$

$$\log f(x|\theta) = x \log \theta + (1-x) \log(1-\theta)$$

$$\frac{\partial \log f(x|\theta)}{\partial \theta} = \frac{x}{\theta} - \frac{1-x}{1-\theta}$$

$$\frac{\partial^2 \log f(x|\theta)}{\partial \theta^2} = -\frac{x}{\theta^2} - \frac{1-x}{(1-\theta)^2}.$$

Stąd

$$I(\theta) = -E \left[-\frac{x}{\theta^2} - \frac{1-x}{(1-\theta)^2} \right] = \frac{\theta}{\theta^2} + \frac{1-\theta}{(1-\theta)^2} = \frac{1}{\theta} + \frac{1}{1-\theta} = \frac{1}{\theta(1-\theta)}.$$

Przykład 2

X_1, \dots, X_n iid, takie że

$$X_i = \theta + e_i, \quad i=1, \dots, n, \quad (\text{model potoczenia przesunięcia})$$

gdzie e_1, \dots, e_n iid $e_i \sim f(x)$. Wtedy $X_i \sim f(x-\theta)$.

Założymy, że f spełnia warunki regularności. Wtedy

$$I(\theta) = \int_{-\infty}^{\infty} \left(\frac{f'(x-\theta)}{f(x-\theta)} \right)^2 f(x-\theta) dx = \int_{-\infty}^{\infty} \left(\frac{f'(z)}{f(z)} \right)^2 f(z) dz.$$

Zatem w modelu presunigia informacji Fishera nie zależy od θ .

Załóżmy, że X_i ma rozkład Laplace'a. $f(x_i|\theta) = \frac{1}{2}e^{-|x_i-\theta|}$

Ponieważ

$$X_i = \theta + e_i,$$

wówczas

$$e_i \sim f(z_i) = \frac{1}{2}e^{-|z_i|}$$

Ponadto, $f'(z) = -\frac{1}{2}e^{-|z|}\operatorname{sgn}(z)$.

Tym samym

$$I(\theta) = \int_{-\infty}^{\infty} \left(\frac{f'(z)}{f(z)} \right)^2 f(z) dz = \int_{-\infty}^{\infty} f(z) dz = 1.$$



Uwaga 2

Jeżeli X_1, \dots, X_n iid, $X_i \sim f(x|\theta)$ oraz $I(\theta)$ jest informacją Fishera X_1 , to $nI(\theta)$ jest informacją Fishera dla całej próby.

Dowód

$$\frac{\mathbb{E}}{\text{Var}} \left(\frac{\partial \log L(\theta, X)}{\partial \theta} \right) = \left(\sum_{i=1}^n \frac{\partial \log f(X_i; \theta)}{\partial \theta} \right) = \sum_{i=1}^n \text{Var} \left(\frac{\partial \log f(X_i; \theta)}{\partial \theta} \right) = nI(\theta).$$

Tu. 1 (Nierówność Granera-Rao)

Niech X_1, \dots, X_n będą niezależnymi zmieniami losowymi z gęstością $f(x|\theta)$ $\theta \in \Theta$. Założymy, że warunki regularności (P0)-(R4) są spełnione.

Jeżeli $Y = u(X_1, \dots, X_n)$ jest taka statystyką t.p. $EY = E[u(X_1, \dots, X_n)] = k(\theta)$, to $\text{Var}(Y) \geq \frac{[k'(\theta)]^2}{nI(\theta)}$.

Dowód

I P Założymy, że X_1 ma rozkład ciągły (dla dyskretnych analogicznie)