

Zatem w modelu presunigia informacji Fishera nie zależy od θ .

Załóżmy, że X_i ma rozkład Laplace'a. $f(x_i|\theta) = \frac{1}{2}e^{-|x_i-\theta|}$

Ponieważ

$$X_i = \theta + e_i,$$

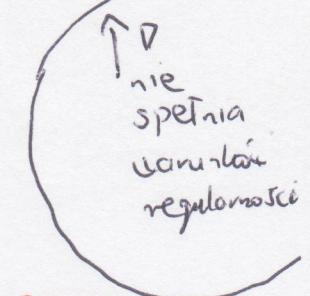
wówczas

$$e_i \sim f(z_i) = \frac{1}{2}e^{-|z_i|}$$

Ponadto, $f'(z) = -\frac{1}{2}e^{-|z|} \operatorname{sgn}(z)$.

Tym samym

$$I(\theta) = \int_{-\infty}^{\infty} \left(\frac{f'(z)}{f(z)} \right)^2 f(z) dz = \int_{-\infty}^{\infty} f(z) dz = 1.$$



Uwaga 2

Jeżeli X_1, \dots, X_n iid, $X_i \sim f(x|\theta)$ oraz $I(\theta)$ jest informacją Fishera X_1 , to $nI(\theta)$ jest informacją Fishera dla całej próbki.

Dowód

$$\frac{\partial}{\partial \theta} \left(\frac{\partial \log L(\theta, X)}{\partial \theta} \right) = \operatorname{Var} \left(\sum_{i=1}^n \frac{\partial \log f(X_i; \theta)}{\partial \theta} \right) = \sum_{i=1}^n \operatorname{Var} \left(\frac{\partial \log f(X_i; \theta)}{\partial \theta} \right) = n I(\theta).$$

Tu. 1 (Nierówność Granera-Rao)

Niech X_1, \dots, X_n będą niezależnymi zmieniami losowymi z gęstością $f(x|\theta)$ $\theta \in \Theta$. Założymy, że warunki regularności (P0)-(R4) są spełnione.

Jeżeli $Y = u(X_1, \dots, X_n)$ jest taka statystyką t.p. $EY = E[u(X_1, \dots, X_n)] = k(\theta)$, to $\operatorname{Var}(Y) \geq \frac{[k'(\theta)]^2}{n I(\theta)}$.

Dowód

I P Założymy, że X_1 ma rozkład ciągły (dla dyskretnych analogicznie)

$$1. \text{ Many } k(\theta) = EY_1 = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} u(x_1, \dots, x_n) f(x_1, \theta) \cdots f(x_n, \theta) dx_1 \cdots dx_n.$$

2. Stąd

$$k'(\theta) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} u(x_1, \dots, x_n) \left[\sum_{i=1}^n \frac{1}{f(x_i, \theta)} \frac{\partial f(x_i, \theta)}{\partial \theta} \right] f(x_1, \theta) \cdots f(x_n, \theta) dx_1 \cdots dx_n$$

$$= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} u(x_1, \dots, x_n) \left[\sum_{i=1}^n \frac{\partial \log f(x_i, \theta)}{\partial \theta} \right] f(x_1, \theta) \cdots f(x_n, \theta) dx_1 \cdots dx_n$$

$$3. \text{ Zdefiniujmy z n. los } I = \sum_{i=1}^n \frac{\partial \log f(x_i, \theta)}{\partial \theta}.$$

$$4. \text{ Wtedy } EI = 0, \text{ Var } I = nI(\theta).$$

$$5. \text{ Ponadto, } k'(\theta) = E[YZ] = E(Y)E(Z) + g\overline{Y}\sqrt{nI(\theta)}, \stackrel{(4)}{=} g\overline{Y}\sqrt{nI(\theta)}.$$

$$6. \text{ Stąd gdzie } g = \text{corr}(Y, Z).$$

$$k'(\theta) =$$

6. Stąd

$$S = \frac{k'(\theta)}{\overline{Y}\sqrt{nI(\theta)}}.$$

7. Ponieważ $g^2 \leq 1$, zatem

$$\frac{[k'(\theta)]^2}{\overline{Y}^2 nI(\theta)} \leq 1 \Leftrightarrow \text{Var } Y \geq \frac{[k'(\theta)]^2}{nI(\theta)}.$$

Wniosek 1

Ponyższym zapisie potwierdzamy, jeżeli $Y = u(X_1, \dots, X_n)$ jest nieobciążonym estymatorem $\hat{\theta}$ (paranormy), ($k(\theta) = \theta$), to

$$\text{Var } Y \geq \frac{1}{nI(\theta)}.$$

Przykład 3

$$X_1, \dots, X_n \text{ iid } X_i \sim b(1, \theta). \frac{1}{nI(\theta)} = \frac{\theta(1-\theta)}{n} \quad [\text{byt}]$$

$$\text{Wtedy } E\hat{\theta} = \bar{X}, \text{ a } E\bar{X} = \theta, \text{ Var}\bar{X} = \frac{\theta(1-\theta)}{n}.$$

Zatem wariancja \bar{X} spełnia osiąga dolne ograniczenie

u nieważności Craméra - Rao.

Def 3

Pry założeniuach (R0)-(R1), jeżeli $Y = u(x_1, \dots, x_n)$ jest nieobugzonym estymatorem parametru θ , to liczbę

$$\text{e}_Y = \frac{\frac{1}{n} I(\theta)}{\text{Var } Y} = \frac{1}{n I(\theta) \cdot \text{Var } Y} \quad e_Y \in [0, 1].$$

nazywamy efektywnością estymatora Y .

Przykład 4

X_1, \dots, X_n iid, $X_i \sim \text{Pois}(\theta), \theta > 0$. $E\bar{X} = \bar{X}, E\bar{X} = \theta, \text{Var } \bar{X} = \frac{\theta}{n}$

Mamy $\frac{\partial \log f(x, \theta)}{\partial \theta} = \frac{\partial}{\partial \theta} (\theta \log \theta - \theta - \log x!) = \frac{x}{\theta} - 1,$

$$P(X=x) = \frac{\theta^x e^{-\theta}}{x!}$$

$$E\left[\frac{\partial \log f(x, \theta)}{\partial \theta}\right]^2 = E\left(\frac{x}{\theta} - 1\right)^2 = \frac{1}{\theta^2} E[x^2] = \frac{1}{\theta^2} \sigma_x^2 = \frac{\theta}{\theta^2} = \frac{1}{\theta}.$$

$$e_Y = \frac{1}{\left(n \frac{1}{\theta} \cdot \frac{\theta}{n}\right)} = 1.$$

\bar{X} - estymator efektywny.

Przykład 5

X_1, \dots, X_n iid $X_i \sim f(x, \theta) = \begin{cases} \theta x^{\theta-1}, & x \in (0, 1) \\ 0 & \text{in pp.} \end{cases}$ Beta($\theta, 1$).
 $\theta \in \Theta = (0, \infty)$.

$$\frac{\partial \log f(x, \theta)}{\partial \theta} = \frac{\partial \log \theta + (\theta+1) \log x}{\partial \theta} = \frac{1}{\theta} + \log x$$

$$\frac{\partial^2 \log f(x, \theta)}{\partial \theta^2} = -\frac{1}{\theta^2}. \quad \text{Zatem } I(\theta) = \frac{1}{\theta^2}$$

$$l(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i, \theta) = n \log \theta + \theta \sum_{i=1}^n \log x_i - \sum_{i=1}^n \log x_i.$$

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^n \log x_i = 0 \Rightarrow \hat{\theta} = -\frac{n}{\sum_{i=1}^n \log x_i}.$$

Def Mied Y_i = -log X_i. Wtedy Y_i ~ Γ(1, $\frac{1}{\theta}$), W = $\sum_{i=1}^n Y_i \sim \Gamma(n, \frac{1}{\theta})$ (40)

Ponieważ $EW^k = \frac{(n+k-1)!}{\theta^k(n-1)!}$ dla $k > -n$. To

$$E\hat{\theta} = n E[W^{-1}] = n \cdot \frac{(n-2)!}{\theta^{-1}(n-1)!} = \theta \frac{n}{n-1}.$$

$$E\hat{\theta}^2 = n^2 E[W^{-2}] = \theta^2 n^2 \frac{(n-3)!}{\theta^2(n-1)!} = \theta^2 \frac{\cancel{\theta} \cdot n^2}{(n-1)(n-2)}.$$

W rezultacie

$$\text{Var } \hat{\theta} = E\hat{\theta}^2 - (E\hat{\theta})^2 = \theta^2 \frac{n^2}{(n-1)(n-2)} - \theta^2 \frac{n^2}{(n-1)^2} = \theta^2 \frac{\cancel{n^2(n-1)} - \cancel{n^2(n-1)}}{(n-1)^2(n-2)} = \theta^2 \frac{n^2}{(n-1)^2(n-2)}.$$

Oraz

$$e_{\hat{\theta}} = \frac{1}{n I(\theta) \text{Var } \hat{\theta}} = \frac{1}{n \frac{1}{\theta^2} \cdot \frac{\theta^2 n^2}{(n-1)^2(n-2)}} = \frac{(n-1)^2(n-2)}{n^3} < 1.$$

$\hat{\theta}$ - nie jest efektywny, ale jest asymptotycznie efektywny.

Założenie

jakaś fuk

(R5): Gestosí $f(x|\theta)$ jest trzykrotnie różniczkowalny względem θ .

Ponadto, dla wszystkich $\theta \in \mathbb{H}$, istnieje stała c i funkcja $H(x)$,

taka że

$$\left| \frac{\partial^3}{\partial \theta^3} \log f(x|\theta) \right| < H(x), \quad \text{a } E_{\theta_0}[H(x)] < \infty$$

dla wszystkich $\theta_0 - c < \theta < \theta_0 + c$ i wszystkich x należących do obszaru X .

Tu. 2

Założymy, że X_1, \dots, X_n są iid z gestosím $f(x|\theta_0)$ dla $\theta_0 \in \mathbb{H}$, takie że warunki regularności (R0)-(R5) są spełnione. Założymy, że informacja

Fishera spełnia warunek $0 < I(\theta_0) < +\infty$. Wtedy, kiedy zgodny ciąg $\{\hat{\theta}_n\}$ jest rozwiązaniem równania $\frac{d}{d\theta} L(\theta) = \frac{d}{d\theta} L(\theta, X_n) = 0$ spełnia warunek $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, \frac{1}{I(\theta_0)})$.

Dowd

1. Z równania $\ell'(\theta)$ i szereg Taylora ~~w punkcie do many~~

$$\ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0)\ell''(\theta_0) + \frac{1}{2}(\hat{\theta}_n - \theta_0)^2\ell'''(\theta_n^*),$$

gute $\hat{\theta}_n^* \in (\theta_0, \hat{\theta}_n) \cup (\hat{\theta}_n, \theta_0)$.

2. Ponieważ $\ell'(\hat{\Theta}_n) = 0$, zatem

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{\frac{1}{\sqrt{n}} \ell'(\theta_0)}{-\frac{1}{n} \ell''(\theta_0) - \frac{1}{2n} (\hat{\theta}_n - \theta_0) \ell'''(\theta_0^*)}.$$

3. Ponieważ $\text{Var}\left(\frac{\partial \log f(x_i|\theta_0)}{\partial \theta}\right) = I(\theta_0) < \infty$,
 $\sum Q_1 \leq CTG$ implika je

$$\frac{1}{\sqrt{n}} \mathbf{e}'(\theta_0) = \frac{1}{n} \sum_{i=1}^n \frac{\partial \log f(x_i, \theta_0)}{\partial \theta} \xrightarrow{D} N(0, I(\theta_0))$$

4. ^{2e} SPLWL

$$-\frac{1}{n} \ell''(\theta_0) = -\frac{1}{n} \sum_{i=1}^n \frac{\partial^2 \log f(x_i; \theta_0)}{\partial \theta^2} \xrightarrow{P} I(\theta_0).$$

$$5. \text{ Ponieważ } \hat{\Theta}_n - \Theta_0 \xrightarrow{P} 0 \text{ (wystarczy zastosować twierdzenie o granicy prawdopodobieństwa)} = O_p(1)$$

6. Z warunkiem (R5) istnieje stała c_0 , taką że $|f_n - f_0| < c_0$

7. Step $|\theta_n^* - \theta_0| < c_0$ oral \star

$$\left| -\frac{1}{n} \ell'''(\theta_n^*) \right| \leq \frac{1}{n} \sum_{i=1}^n \left| \frac{\partial^3 \log f(x_i | \theta)}{\partial \theta^3} \right| \Big|_{\theta=\theta_n^*} \leq \frac{1}{n} \sum_{i=1}^n H(x_i) \xrightarrow{P} E_{\theta_0}[H(X)]$$

8. Nied $\Sigma T_0^q N_2 : N_2$ bpdg talié, te

$$\text{dla } n \geq N_1 \rightarrow P(|\hat{\theta}_n - \theta_0| < \epsilon_0) \geq 1 - \frac{\delta}{2}$$

$$n \geq N_2 \Rightarrow P\left(\left|\frac{1}{n} \sum_{i=1}^n h(X_i) - E_{\theta_0}[h(X)]\right| < 1\right) \geq 1 - \frac{\epsilon}{2}$$

g. Zatem, dl

$$n > \max\{N_1, N_2\} \Rightarrow P\left(\left|\frac{1}{n}\ell'''(\theta_n^*)\right| \leq 1 + E_{\theta_0}[M(x)]\right) \geq 1 - \frac{\epsilon}{2}$$

$$\text{co-efekcijski teorem} \quad \frac{1}{n} \ell'''(\theta_n^*) = O_p(1).$$

Def 4

Niech x_1, \dots, x_n będące nierelatynymi zmiennymi losowymi o gęstości $f(x|\theta)$.
 Zatem $\hat{\theta}_{1n} = \hat{\theta}_{1n}(x_1, \dots, x_n)$ jest estymatorem parametru θ_0 , takim że
 $\sqrt{n}(\hat{\theta}_{1n} - \theta_0) \xrightarrow{D} N(0, \frac{1}{I(\theta_0)})$, gdzie ~~$\frac{1}{I(\hat{\theta}_{1n})} = \text{Var}(\hat{\theta}_{1n})$~~ . Wtedy

(i) Wówczas

$$e(\hat{\theta}_{1n}) = \frac{1/I(\theta_0)}{\sigma_{\hat{\theta}_{1n}}^2}$$

nazywamy asymptotyczną efektywnością estymatora $\hat{\theta}_{1n}$.

(ii) Jeżeli $e(\hat{\theta}_{1n}) = 1$, to mówimy, że estymator $\hat{\theta}_{1n}$ jest asymptotycznie efektywny.

Niech $\hat{\theta}_{2n}$ będzie innym estymatorem parametru θ_0 , takim że
 $\sqrt{n}(\hat{\theta}_{2n} - \theta_0) \xrightarrow{D} N(0, \frac{1}{I(\theta_0)})$. Wtedy, wówczas

$$e(\hat{\theta}_{1n}, \hat{\theta}_{2n}) = \frac{\sigma_{\hat{\theta}_{2n}}^2}{\sigma_{\hat{\theta}_{1n}}^2}$$

nazywamy asymptotyczną efektywnością względem estymatora $\hat{\theta}_{1n}$
 względem $\hat{\theta}_{2n}$.

Przykład 5

~~x_1, \dots, x_n iid,~~

$$X_i = \theta + e_i \quad i=1, \dots, n, \quad e_1, \dots, e_n \text{ iid}, \quad e_i \sim \text{Laplace}'a$$

EWW parametru θ jest $\hat{\theta}_1 = \text{me}\{X_1, \dots, X_n\} = Q_e$, $I(\theta_0) = \frac{1}{2}e^{-|x|}$.

$$\sqrt{n}(\hat{\theta}_1 - \theta) \xrightarrow{D} N(0, 1)$$

Niech $\hat{\theta}_2 = \bar{X}$, CTE implikuje $\sqrt{n}(\hat{\theta}_2 - \theta) \xrightarrow{D} N(0, \sigma^2)$,
 gdzie $\sigma^2 = \text{Var} X_1 = \text{Var}(e_1 + \theta) = \text{Var}(e_1) = Ee_1^2 = \int_{-\infty}^{\infty} z^2 \frac{1}{2}e^{-|z|} dz =$

$$\int_0^{\infty} z^2 e^{-z} dz = \Gamma(3) = 2.$$

$$\text{Zatem } e(\hat{\theta}_1, \bar{X}) = \frac{2}{1} = 2$$

Medianą dla nocy bardziej efektywną jest $\hat{\theta}_1$.

(ii) $e_i \sim N(0, 1)$. Wtedy

$$\sqrt{n}(\hat{\theta}_1 - \theta) \xrightarrow{D} N(0, \frac{1}{2}), \quad \text{Dla } \sqrt{n}(\hat{\theta}_2 - \theta) \xrightarrow{D} N(0, 1).$$

$$e(M_e, \bar{x}) = \frac{1}{\pi_2} = \frac{2}{\pi} \approx 0.636. = \frac{1}{1.57}$$

$\frac{1}{2f(0)}$

Wniosek (Asymptotyczne) średnia 157 razy bardziej efektywna niż mediana.

Wniosek 4 (Asymptotyczny przedział ufności dla θ)

Na mocy twierdzenia $T_n(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, \frac{1}{I(\theta_0)})$.

Stąd $\frac{1}{\sqrt{n}I(\theta_0)}$ jest asymptotyczną wariancją $\hat{\theta}_n$. Ponieważ $\hat{\theta}_n \xrightarrow{P} \theta_0$, a $I(\theta)$ jest ciągłą funkcją parametru θ , to $I(\hat{\theta}_n) \xrightarrow{P} I(\theta_0)$.

Na tej podstawie, asymptotyczny przedział ufności dla parametru θ na poziomie ufności $1-\alpha$ ma postać

$$\left(\hat{\theta}_n - z(1-\frac{\alpha}{2}) \frac{1}{\sqrt{n}I(\hat{\theta}_n)}, \hat{\theta}_n + z(1-\frac{\alpha}{2}) \frac{1}{\sqrt{n}I(\hat{\theta}_n)} \right), \text{ gdzie}$$

$$z(1-\frac{\alpha}{2}) = \Phi^{-1}(1-\frac{\alpha}{2}).$$

Wniosek 5

Założenie: założeniu twierdzenia 3, założmy, że $g(x)$ jest funkcją ciągłą, różniczkowalną w punkcie θ_0 ozn. $g'(\theta_0) \neq 0$. Wtedy

$$T_n(g(\hat{\theta}_n) - g(\theta_0)) \xrightarrow{D} N(0, \frac{g'(\theta_0)^2}{I(\theta_0)}).$$

3. Numeryczne wyznaczanie estymatorów MLE z użyciem

Metody Newtona

$\hat{\theta}^{(0)}$ - punkt startowy

$$\hat{\theta}^{(1)} = \hat{\theta}^{(0)} - \frac{l'(\hat{\theta}^{(0)})}{l''(\hat{\theta}^{(0)})} + \text{ itd.}$$

Zastosowanie ^{np.} do problemu

Problem Przychód

$$x_1, \dots, x_n \text{ iid } X_i \sim f(x_i; \theta) = \frac{\exp\{-(x_i - \theta)\}}{[1 + \exp\{-(x_i - \theta)\}]^2} \quad x \in \mathbb{R}, \theta \in \mathbb{R}.$$

Problem: wykazać ENU istnieje, ale nie da się go jawnie wyznaczyć!